命题 1 · 数据底座体检（R06 数据分析能力演练）

这套数据能撑多强的结论?

个护订单 + 市场台账的六维体检

先别急着算指标。20,000 行订单 + 76 条市场台账，先过质量、语义、对账三道门：能过的结论留下，过不了的当场降级。

读者：需要拿数据做决策的人

数据：orders.csv（模拟 2 万单）+ 个护台账（真实 76 条）

口径：订单级明细 + 限额以上/全渠道两套市场口径

技能：quality / semantics / scinlp / viz

00 结论先行

结论

这套数据能支撑「结构与对比」，支撑不了「因果与实时」。质量 8.1 分但及时性 0 分，语义层能落地、跨口径对账会失败——失败本身是功能，不是 bug。

能用

20,000 行订单完整、无重复、GMV 1,903,705.87 元与客单价 95.19 元可逐行复算；语义模型 4 个 measure、3 个 metric 全部通过校验。

不能用

最新订单距统计日 40 天，超过 14 天 SLA，不能用来做日报；订单是模拟数据，任何对外结论都必须标注来源。

订单行数	质量总分	语义校验	GMV	跨口径对账
20,000	8.1/10	PASS	190.4 万	FAIL
17 列，主键唯一（quality）	六维规则命中，及时性 0 分	4 measure / 3 metric	明细直接求和，可复算	差 -57.9%，已给根因

1 质量：8.1 分不是好消息，及时性是 0 分

2 语义：口径能落地，但对账必须显式

3 分布：客单价右偏，均值不是典型值

4 判断：这套数据能撑多强的结论

5 口径与分数

1 质量：8.1 分不是好消息，及时性是 0 分

本节问题 这批订单数据能不能直接进分析？六个维度里哪一维最危险？

数据质量六维得分（满分 10） 分；分母为各维度规则数



quality audit（R06 s02）；数据 orders.csv，20,000 行 × 17 列

读图

1. **总分**：8.1/10，评级「可用-仅小问题」（20,000 行 × 17 列）。
2. **及时性 0 分**：订单最新日期距统计日 40 天，超过 14 天 SLA——这不是数据错，是「日报口径」不成立；月末批量数据只能做月度分析。
3. **准确性 8 分**：unit_price 离群 522 个、revenue 离群 591 个，只标记不删除；离群集中在高价套装，删掉会低估客单价。
4. **完整性/一致性/唯一性**：缺失 0、重复 0，主键唯一，不需要清洗（clean 跑完 20,000 行未删一行）。

证据边界 质量分是规则命中率，不是业务正确性；「及时性 0」只说明数据不是当天的，不代表过期。

2 语义：口径能落地，但对账必须显式

本节问题 指标定义和真实数据对得上吗？对不上时系统能不能说清为什么？

要点

1. **能落地：**validate 通过、compute 直接算出 GMV 1,903,705.87 元与客单价 95.19 元，语义定义没有悬空。
2. **能对账：**同口径两数差 0% 判 pass；跨口径（统计局限额以上 4,653 亿 vs 香协全渠道 11,042.45 亿）判 fail 并给出根因清单，不让人误以为「数错了」。
3. **已知缺陷：**compute 的 count_distinct 返回去重值列表而不是计数（本次未把它写进结论）；这是技能实现缺陷，不是数据问题。

证据边界 语义层只覆盖 orders 一张表；跨表 join 的口径一致性没有纳入本次校验。

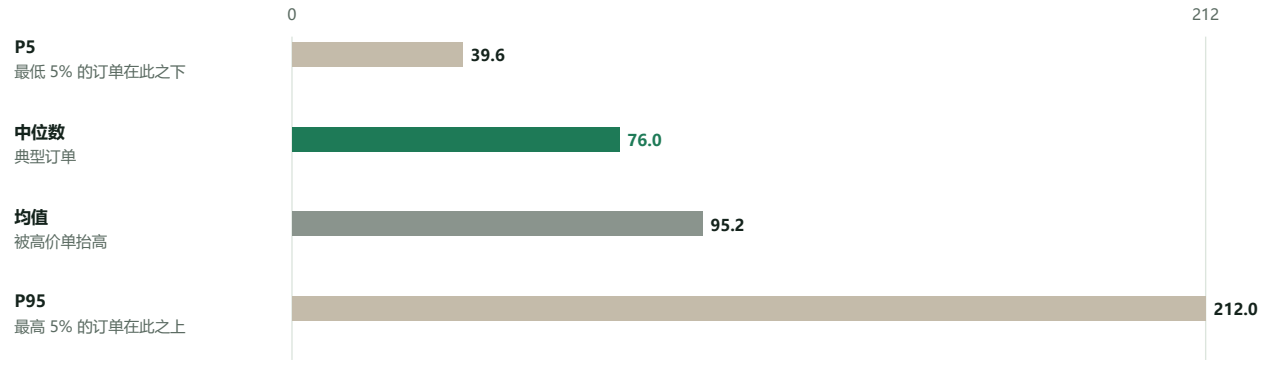
表 1 · 语义层校验与口径对账

检查项	结果	说明
语义模型校验	PASS	1 个模型 / 4 个 measure / 3 个 metric，0 错误
GMV（sum revenue）	1,903,705.87 元	对 20,000 行订单直接求和
客单价（avg revenue）	95.19 元	GMV ÷ 订单数 = 95.19，与明细一致
GMV 对账（同口径）	PASS	两数差 0.0%，容差 1.0%，判定 pass
市场规模对账（跨口径）	FAIL	4,653 亿 vs 11,042.45 亿，差 -57.86%；系统给出 6 条根因（过滤/粒度/定义漂移等）

3 分布：客单价右偏，均值不是典型值

本节问题 用均值代表客单价会误导吗？哪些统计量更该报？

客单价的关键分位（元） 元；订单级 revenue



scinlp describe（R06 s06）与 describe（s05）

读图

1. **右偏：**均值 95.19 元、中位数 75.96 元，偏度 1.52；P95 是 212 元，均值被高价套单抬高。
2. **报法：**对外报客单价应同时给均值 + 中位数 + P95；只报均值会把「典型订单」说贵 25%。
3. **后端：**scipy/statsmodels/numpy/pandas available，spaCy unavailable；NLP 只有简易分词。

证据边界 分位数与偏度只对 orders.csv 成立；不同品类分布不同，不能跨品类套用。

4 判断：这套数据能撑多强的结论

本节问题 哪些结论可以直接用、哪些只能当方向?

要点

1. **结论：**这套数据可以支撑「结构与对比」，不能支撑「因果与实时」；报告里凡是因果表述都必须换成实验或准实验设计。
2. **可视化门禁：**viz spec 校验通过（48 种图表类型可登记）；图表类型选错会被 schema 拦下。
3. **专业域：**domain list 返回 30 项生信技能，后端 omicverse 不在本机，登记为 blocked，不假装能跑。

证据边界 分级只针对本次 20,000 行模拟订单与 76 条个护台账；换数据要重跑质量与语义两道门。

表 2 · 数据可用性分级

结论类型	能不能下	依据 / 限制
总量与结构（GMV、客单价、品类占比）	可以	订单级明细完整、语义校验通过、对账 0 差
趋势与季节性	方向	只有 39 周且为模拟；真实业务需 12 个月以上
因果（渠道/折扣的效果）	不行	只有观测数据，没有随机分配；需实验或 DID（见 P5）
日报级实时性判断	不行	最新日期距今 40 天，超过 14 天 SLA

▸ **附录 A1 • 记录层：质量与语义检查逐条**

5 口径与分数

本节问题 这份报告的结论能追回到哪一步？哪些地方是模拟、哪些是真实？

要点

1. **怎么读：**质量分、语义校验、分布统计都是技能直接输出；报告只做格式化，没有二次计算。
2. **边界：**本报告不评价业务好坏，只回答「数据能不能用、能用到什么程度」。

表 4 · 自检与数据边界

指标	值	说明
技能调用	12	P1 共 12 次 R06 调用，全部 exit 0
数据规模	20,000 行	orders.csv；另有 76 条个护真实台账用于口径对账
真实 / 模拟	1 / 1	对账用的 4,653 亿与 11,042.45 亿是真实公开数；订单是模拟
未采用输出	1	count_distinct 返回值类型异常，未写入结论

口径、来源与证据边界

▾ **口径、模拟标注与已知缺陷**

真实 vs 模拟：orders.csv 为按固定 seed 生成的模拟数据（洗护均价≈53 元、抖音占比 40% 等锚点对齐 2025 公开数据）；4,653 亿、11,042.45 亿为真实公开数。

已知缺陷：semantics compute 的 count_distinct 返回去重值列表而非计数；本报告未使用该输出。

复现：python scripts/gen_data.py && python scripts/derive.py && python scripts/run_skills.py

报告由 core/report_renderer.py 从 contract 确定性渲染；手改 HTML 会在重渲时丢失。
