命题 4 · A/B 实验（R06 数据分析能力演练）

主图改版能不能把转化提上去？

一次 20 万人 A/B 的设计、读出与 SRM 门禁

实验不是「跑完看 p 值」。先算 MDE，再看 SRM，最后才读 lift——这篇用一次 20 万人的模拟实验，把顺序走一遍。

读者：增长 / 产品

数据：200,000 会话（模拟，seed=42）

口径：会话级 CTR/CVR；80% 功效，alpha 0.05

技能：power / abtest / ttest / chi2

00 结论先行

结论

主图改版的 CTR +3.13%、CVR +2.42%，都不显著；承诺的 +8% 没有兑现，判定 no_ship。

为什么

这次只够检出 0.22pp 的绝对提升，实测差异在噪声内；不是「改版无效」，是「证据不够」。

门禁

另一个 52/48 分流的实验 lift 8.89%、p<0.01，但 SRM χ^2=81.6，直接判 rerun——显著不等于可信。

样本	CTR lift	CVR lift	SRM（clean）	决策
20 万	**3.13%**	**2.42%**	**通过**	**不 ship**
10 万/组，满足 80,735/组	p=0.200135	p=0.435006	χ^2=0.00	主指标不显著

1 设计：先算样本量，再看结果

2 读出：CTR +3.1%、CVR +2.4%，都不显著

3 SRM：分流 52/48 的实验，结果再好看也不能用

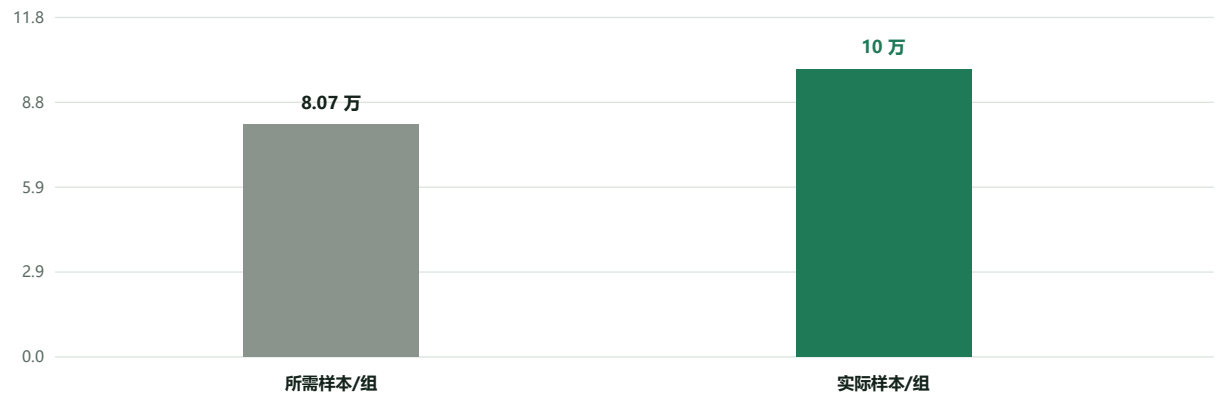
4 分层：设备间没有交互，收入差异也不显著

5 口径与分数

1 设计：先算样本量，再看结果

本节问题 这个实验能检出多大的效果？样本够不够？

功效设计：所需样本量 vs 实际样本量（万/组） 万/组；MDE 0.22pp 见读图



power（R06 s05）：baseline 3.2%，alpha 0.05，power 0.8

读图

1. **样本量：**基线 3.2%、绝对 MDE 0.25pp，需要每组 80,735 个样本（80% 功效）；本次每组 10 万，刚够。
2. **可检出下限：**每组 10 万时 MDE 为 0.22pp（相对 7.0%）；小于这个量级的效果检不出来。
3. **纪律：**先写主指标与 MDE，再开实验；事后改主指标就是 p-hacking。

证据边界 功效按双比例 z 检验正态近似；实际检测用了更保守的 Welch 口径。

2 读出：CTR +3.1%、CVR +2.4%，都不显著

本节问题 主图改版承诺的 +8% 兑现了吗？该不该发？

A/B 两组的主指标（%） %；CTR = click，CVR = convert



abtest（R06 s05），ab_clean.csv 200,000 会话

读图

1. **CTR**：3.29% → 3.40%，lift 3.13%，p=0.200135（不显著）。
2. **CVR**：2.07% → 2.12%，lift 2.42%，p=0.435006，判定 no_ship。
3. **兑现**：承诺 +8% 相对提升，实测 +3.1% / +2.4%，且都在噪声范围内；不能宣布成功。

证据边界 CVR 只统计会话级转化；未覆盖复购与退款，不能代表 GMV 收益。

3 SRM：分流 52/48 的实验，结果再好看也不能用

本节问题 样本比例失配时，显著结果能不能采信？

要点

1. **SRM**：ab_srm 的 χ^2=81.6，远超临界 3.841——分流代码或埋点有问题。
2. **纪律**：SRM 异常时先查分流与去重，不能因为 p<0.05 就宣布胜利；这是实验平台最常见的事故。
3. **正确动作**：重跑实验，确认 50/50 后再读主指标。

证据边界 SRM 只查总量比例；分层后的比例失衡需要额外检查。

表 1 · 两个实验的 SRM 与决策

实验	SRM χ^2	lift	决策
ab_clean（50/50）	0.00	2.42%	no_ship（无 SRM）
ab_srm（52/48）	81.6	8.89%	srm_rerun（显著也不采信）

4 分层：设备间没有交互，收入差异也不显著

本节问题 效果是否集中在某类设备？收入有没有变化？

要点

1. **设备：** iOS/Android/PC 的转化差异不显著，改版效果没有集中在某一端。
2. **收入：** 两组收入差异 -0.10 元、p=0.271516；即使 CVR 小幅上升，也没有转化为可测的收入增量。
3. **结论：** 不 ship；把预算留给下一次改版，或把样本量提到 20 万/组再测。

证据边界 分层检验未做多重比较校正；设备维度只有 3 层，检验力有限。

表 2 · 分层与收入检验

检验	统计量	判读
设备 × 转化（卡方）	2.10	临界 5.991，不显著（V=0.0032）
收入（Welch t）	-1.10	p=0.271516，d=-0.0049（small）

▸ **附录 A1 • 记录层：4 次实验读数**

5 口径与分数

本节问题 这份报告的结论能追回到哪一步？哪些地方是模拟、哪些是真实？

要点

1. **怎么读：** lift = (处理−对照)/对照；SRM 用卡方检验分流比例；MDE 由功效公式反解。
2. **边界：** 模拟实验不能替代线上真实实验；但流程与判定规则可直接复用。

表 4 · 自检与数据边界

指标	值	说明
技能调用	7	P4：power×2 / abtest×3 / ttest / chi2
样本	200,000	10 万/组；SRM 版 19.6 万
真实 / 模拟	全模拟	按真实实验规范生成，结论只演示方法
决策	no_ship	主指标不显著，SRM 版判 rerun

口径、来源与证据边界

▾ **模拟实验与判定规则**

模拟：200,000 会话按 seed=42 生成；基线 CTR 3.2%、CVR 2.1%，与公开个护电商基准同量级。

判定：ship 需同时满足：显著正、lift≥3%、无 SRM；否则 no_ship；SRM 异常一律 rerun。

复现：results/abtest_*.json 保留了每组均值、p 值、SRM χ^2 与决策。

模拟实验只证明流程可跑；真实上线前仍需按同一 MDE 重新设计。